

MC-MATCH

Bakgrund

Vi valde att utveckla "Motorcycle Match" utifrån vårt gemensamma intresse för motorcyklar. Målet var att skapa ett projekt där vi kunde kombinera regression och klassificering med en praktisk användning. Projektet riktar sig både till personer som funderar på att köpa motorcykel och till personer som redan äger en motorcykel och vill få en uppskattning av dess värde.

I Motorcycle Match anger användaren bland annat önskat utseende, hästkrafter, slagvolym, antal säten, antal cylindrar och budget. Utifrån dessa preferenser predikterar klassificeringsmodellen ett användningsområde och systemet presenterar därefter de fem motorcyklar som bäst matchar användarens önskemål. Den andra delen av projektet använder regression för att uppskatta priset på en motorcykel utifrån dess egenskaper.

En av de största utmaningarna var att hitta ett dataset som passade vårt syfte. Datasetet var relativt litet, vilket begränsar förutsättningarna för machine learning-modellerna och deras möjlighet att generalisera. Samtidigt gjorde den begränsade storleken det möjligt för oss att granska och bearbeta datan mer noggrant.

Datakvaliteten visade sig vara en viktig del av projektet. Datasetet innehöll bland annat orimliga priser och inkonsekventa kategorinamn. Exempelvis kunde samma växellådstyp förekomma som 6-speed manual, six-speed manual och six-speed-manual. Vi normaliserade därför kategorierna för att minska antalet onödiga klasser och skapa mer konsekventa variabler. Priserna konverterades från INR till SEK och uppenbart orimliga värden justerades. Vi hanterade även missing values under processen.

Regression var relativt enkelt att koppla till projektets syfte genom att använda en modell för prisestimering. Klassificeringen var däremot mer utmanande eftersom vi först behövde identifiera ett användbart mål. Vi skapade därför variabeln "Usage Type", som grupperar motorcyklarna efter användningsområde, exempelvis Street, Cruise, Touring, Race och Off-road.

Vi jämförde flera klassificeringsmodeller och undersökte även feature importance. Random Forest gav bäst förutsättningar för vår klassificering och vi använde `class_weight="balanced"` för att hantera obalansen mellan klasserna. Den största klassen, Street, var betydligt större än flera av de andra klasserna.

Genom att balansera modellen försökte vi därför förbättra möjligheten att klassificera även de mindre klasserna, även om detta kunde påverka den totala accuracy. Vid utvärderingen fokuserade vi därför främst på F1-score, och särskilt macro F1, eftersom det ger en mer rättvis bild av modellens prestation över samtliga klasser. Accuracy kan annars bli missvisande när en klass är betydligt större än de andra, eftersom modellen kan få hög accuracy genom att vara bra på den största klassen men samtidigt prestera sämre på de mindre klasserna.

En viktig avvägning var vilka features som skulle användas i klassificeringsmodellen. När fler variabler användes blev modellens resultat bättre, men vi valde till slut ett mindre antal

variabler som en användare rimligtvis kan ange utan att behöva ha djup teknisk kunskap om motorcyklar. Detta innebär en kompromiss mellan modellens prestanda och användarvänlighet.

Under projektet insåg vi också att klassificeringsmodellen inte i sig behövdes för att skapa själva matchningen. En vanlig funktion hade kunnat jämföra användarens preferenser med motorcyklarna och rangordna resultaten. Vi valde därför att ge modellerna olika roller. Klassificeringsmodellen används för att identifiera vilket användningsområde som bäst motsvarar användarens angivna preferenser. Därefter används matchningsfunktionen för att hitta och rangordna de konkreta motorcyklar i datasetet som bäst överensstämmer med dessa preferenser.

Huvudresultat

Projektets slutresultat består av två delar. Den första är en Linjär Regression-modell som används för att uppskatta priset på en motorcykel utifrån dess egenskaper.

Den andra delen är Motorcycle Match, där användarens preferenser används som input till en Random Forest Classifier. Modellen predikterar ett "Usage Type" och därefter filtreras och rangordnas motorcyklarna utifrån användarens krav och preferenser. Systemet presenterar de fem motorcyklar som får högst Match Score.

Klassificeringsmodellen gav ett användbart resultat, men resultatet hade kunnat vara bättre. Den begränsade mängden data och det relativt begränsade antalet features som används av modellen påverkar förutsättningarna. Samtidigt var valet av features medvetet eftersom användaren ska kunna använda applikationen utan att behöva ange ett stort antal avancerade motorcykelspecifikationer.

Även regressionsmodellen hade begränsningar. Det relativt lilla datasetet innehåller inte tillräckligt många exempel för alla typer och prisklasser av motorcyklar. Detta gör att modellen får sämre förutsättningar att uppskatta priser för delar av datan där det finns få liknande observationer. Ett större och mer representativt dataset hade därför varit en viktig förbättring.

Teknisk specifikation

Projektet är utvecklat i Python och Jupyter Notebook användes huvudsakligen för dataanalys, visualisering och träning av modellerna. Streamlit används för frontend och för att göra modellerna tillgängliga genom ett användargränssnitt.

Machine learning:

- Random Forest Classifier – klassificering av Usage Type
- Linjär Regression – prisestimering

Bibliotek:

- Pandas – inläsning och bearbetning av data

- NumPy – numerisk databehandling
- Scikit-learn – machine learning och modellutvärdering
- Matplotlib – visualisering
- Joblib – sparning och inläsning av tränade modeller
- Streamlit – användargränssnitt

Datasetet innehöll ursprungligen variabler som Company, Country of Origin, Model, Number of cc, Horsepower, Torque, Transmission Type, Drivetrain, Number of Seating, Year, Looks, Body Type, Engine Type, Number of Cylinders och Price. Vi skapade även variabeln Usage Type för klassificeringsmodellen.

Kategoriska variabler transformerades med One-Hot Encoding för att kunna användas av machine learning-modellerna. Datan delades upp i train-, validation- och testdata under modellutvecklingen.

Utvärdering av gruppens arbete

Git och GitHub har fungerat bra som en central del av vårt samarbete. Vi arbetade i separata och beskrivande branches och använde pull requests mot main, där en annan gruppmedlem genomförde code review innan ändringarna mergades. Detta skapade en tydlig arbetsprocess och gjorde det lättare att följa projektets utveckling.

Vi hade även dagliga stand-ups och code-alongs där vi kunde hjälpa varandra att lösa problem och diskutera olika tekniska lösningar. Arbetet kunde dessutom delas upp relativt enkelt mellan oss eftersom projektet innehöll både en klassificerings- och en regressionsdel, samtidigt som vi kunde granska och hjälpa varandra med respektive del.

Den viktigaste lärdomen från projektet är att datan är grunden för en machine learning-lösning. Datakvaliteten påverkar både modellens resultat och hur användbar den färdiga applikationen blir. Vi fick därför en större förståelse för hur mycket arbete som kan krävas innan själva modellträningen ens börjar.

Vi lärde oss också vikten av att utgå från problemet och användningen innan man väljer modell. I början fokuserade vi mycket på att träna och utvärdera klassificeringsmodellen. När modellen var färdig blev det tydligt att den inte automatiskt löste vår huvudsakliga matchningsfunktion. Det gjorde att vi behövde tänka om kring modellens roll och kombinera machine learning med en separat matchningsfunktion.

Om vi skulle göra projektet igen hade vi framför allt velat börja med en ännu tydligare frågeställning och ett större dataset. Ett större och mer konsekvent dataset hade gett bättre förutsättningar för både regression och klassificering. Samtidigt har projektet visat oss att det är viktigt att först förstå vad datan faktiskt kan användas till och hur resultatet ska användas, innan man bestämmer vilken modell som ska tränas.